CVPR 2026 Best Paper

Efficiently Reconstructing Dynamic Scenes One D4RT at a Time

IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) 2026
Colorado Convention Center, Denver, Colorado, United States · June 2026

Chuhan Zhang, Guillaume Le Moing, Skanda Koppula, Ignacio Rocco, Liliane Momeni, Junyu Xie, Shuyang Sun, Rahul Sukthankar, Joëlle K. Barral, Raia Hadsell, Zoubin Ghahramani, Andrew Zisserman, Junlin Zhang, Mehdi S. M. Sajjadi

主要單位： Google DeepMind 。 Skanda Koppula 另掛 University College London ； Andrew Zisserman 另掛 University of Oxford 。 Junyu Xie 標示為 University of Oxford ， 並註明於 Google DeepMind 實習期間完成。通訊作者： Mehdi S. M. Sajjadi

報告人 第 17 組

廖晢勛 B1229009 ／ 林威宇 B1229010

指導教授 陳仁暉 | 長庚大學 電腦視覺

專案頁 https://d4rt-paper.github.io/

問題

什麼是動態 4D 重建?

深度 + 點雲

每個可見點離相機有多遠，並放進同一個三維空間

三維軌跡

同一個物理點隨著時間跑到哪裡

完整相機參數

每一幀相機在哪、朝哪，以及鏡頭內參

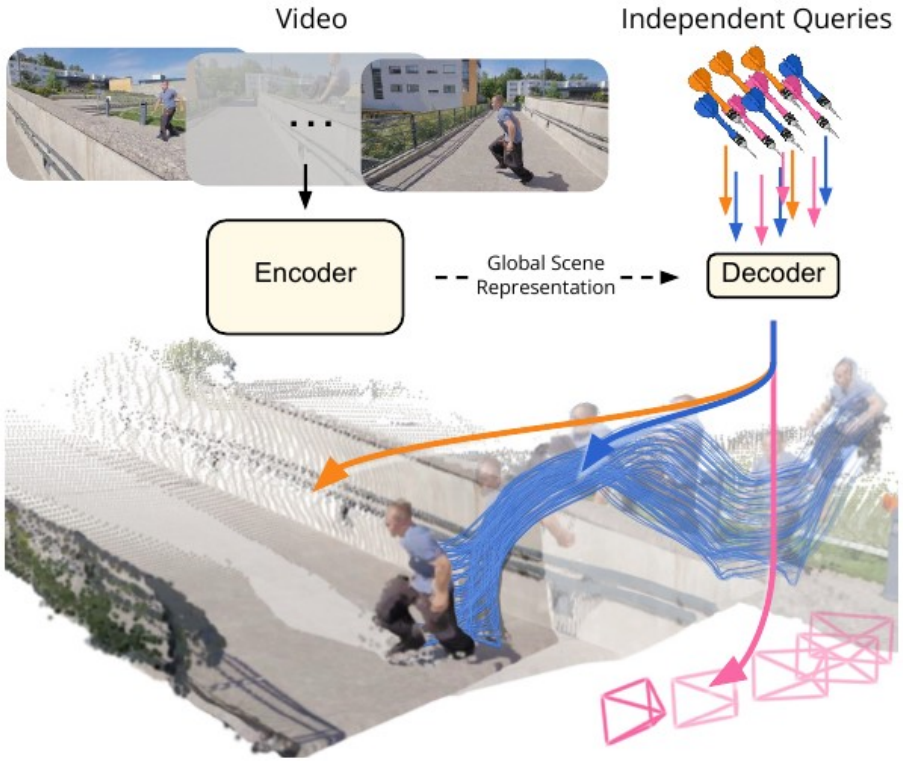


Figure 1. **D4RT** is a unified, efficient, feedforward method for ***D**ynamic **4D** **R**econstruction and **T**racking*, unlocking a variety of outputs including point cloud ( ), point tracks ( ), camera parameters ( ) through a single interface.

論文 Figure 1 ・ 橘：點雲 藍：軌跡 粉：相機

舊方法把問題切成很多塊

01

MegaSaM

拼接多個現成模型，再做昂貴的測試時優化

02

VGGT 等前饋方法

能做三維重建，但通常要多個解碼頭；也難處理動態對應

03

SpatialTrackerV2

有動態追蹤，但不是單一階段，依賴反覆 refinement

Model	Task		Functionality		Architecture	
	3D Reconstruction	Dynamic Correspondence	Flexible Ref. Frames	Sparse Decoding	Global Context	Single Decoder
MegaSaM [32]	✓	✗	✗	✗	✗	✗
DUSt3R[54]	✓	✗	✗	✗	✗	✗
VGGT [51]	✓	✗	✗	✗	✓	✗
π^3 [57]	✓	✗	✓	✗	✓	✗
St4RTrack [13]	✓	✓	✗	✗	✗	✗
STv2 [59]	✓	✓	✗	✓	✓	✗
D4RT (Ours)	✓	✓	✓	✓	✓	✓

D4RT 的轉向

不要每一幀、每一種輸出都密集解碼。

改成需要時才查詢：一次問一個點的三維位置。

先對齊五個名詞

深度與點雲

深度是每個像素離相機多遠。有了深度，就可以把像素放回三維，變成點雲。

內參／外參

內參是鏡頭規格（焦距、主點）。外參是相機在空間中的位置與朝向。

對應與追蹤

不同幀上的像素若是同一個物理點，串起來就是軌跡；加上三維座標就是三維追蹤。

相機座標 vs 世界座標

可以用某一幀相機的眼睛來寫，也可以把整段影片放到同一個共用座標系。

為什麼要先對齊尺度

單鏡頭分不出「近處的小東西」和「遠處的大東西」，所以評估前先對齊整體尺度再比形狀。

核心想法：一次只問一個點的三維位置

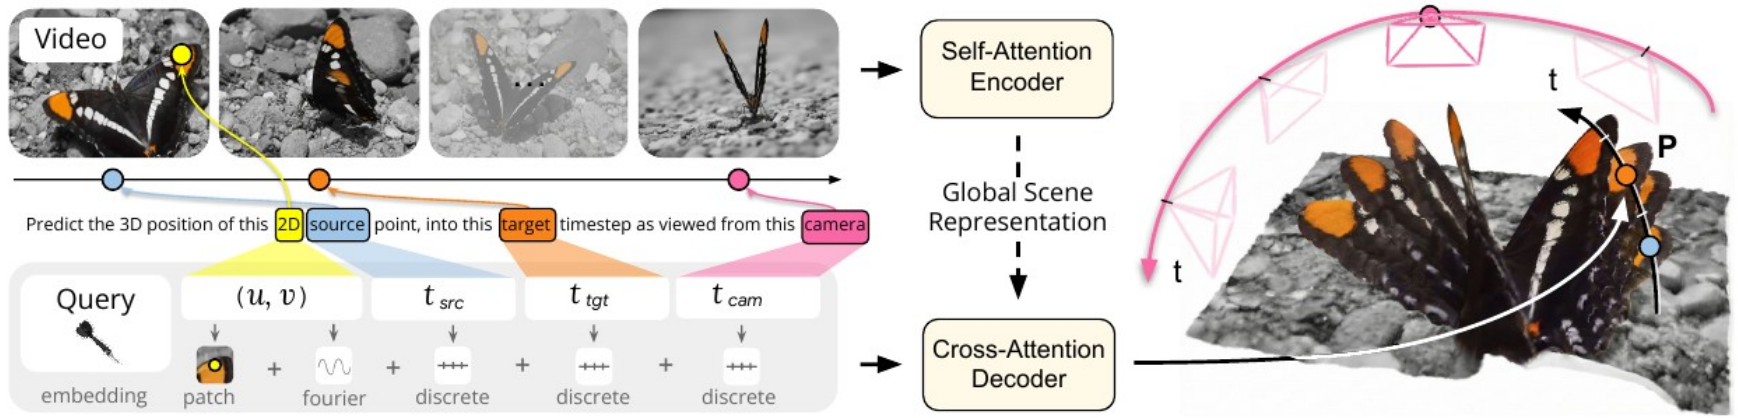


Figure 2. **D4RT model overview** – A global self-attention encoder first transforms the input video into the latent *Global Scene Representation* F, which is passed to a lightweight decoder. The decoder can be independently queried for the *3D position* $\mathbf{P}$ of any given 2D point (u, v) from the source timestep t_{src} at target timestep t_{tgt} in camera coordinate t_{cam}, unlocking full decoding at any point in space and time. The query also contains an embedding of the local video patch centered around (u, v), providing additional spatial context.

q = (u , v , t_src , t_tgt , t_cam) → P = D(q, F)

白話：來源幀上的這個二維點，在目標時間、用這個相機座標系來寫，它的三維位置在哪裡？
三個時間不必相同，於是空間和時間被拆開。每個 query 獨立回答。

論文 Table 1

一個介面，五種輸出

Task	Query				
	u	v	t_{src}	t_{tgt}	t_{cam}
Point Track	Fixed	Fixed	Fixed	$1 \ldots T$	
Point Cloud	$1 \ldots W$	$1 \ldots H$	$1 \ldots T$		Fixed
Depth Map	$1 \ldots W$	$1 \ldots H$	$1 \ldots T$		
Extrinsics	$1 \ldots h$	$1 \ldots w$	Fixed		$1 \ldots T$
Intrinsics	$1 \ldots h$	$1 \ldots w$	$1 \ldots T$		

相機也走同一套 query

外參：同一批點問兩個座標系，再用 Umeyama（一次 3×3 SVD）求剛體變換。

內參（針孔、主點 0.5, 0.5）：
fx = pz (u − 0.5) / px
fy = pz (v − 0.5) / py
再對多個點取中位數。

沒有另外的姿勢輸出頭。

點雲那一列： t_src = t_tgt ， 一起走過 1⋯T ， t_cam 固定。

模型：重的編碼器，輕的解碼器

編碼器 E

ViT-g · 40 層 · 約 10 億參數
時空 patch 2×16×16
交錯的幀內局部注意力 + 跨幀全域注意力
先縮成正方形；原長寬比另做一個 token
初始化：公開的 VideoMAEv2

解碼器 D

8 層 cross-attention · 1.44 億參數
Query = Fourier(u,v) + 三個時間嵌入 + 9×9 RGB 小塊
每個 query 獨立解碼，不做彼此的 self-attention
早期實驗：打開後推論表現大幅下降
一致性寫進全域特徵 F，而不是靠解碼器互相對答案

訓練：48 幀、256×256、每次 2048 個 query、AdamW、50 萬步、64 顆 TPU、兩天多。

為什麼快：只解需要問的點

1 先算一次全域特徵 F

2 用佔用格點記住哪些時空像素已被拜訪

3 只從沒走過的像素長出新軌跡（加速約 5–15 倍）

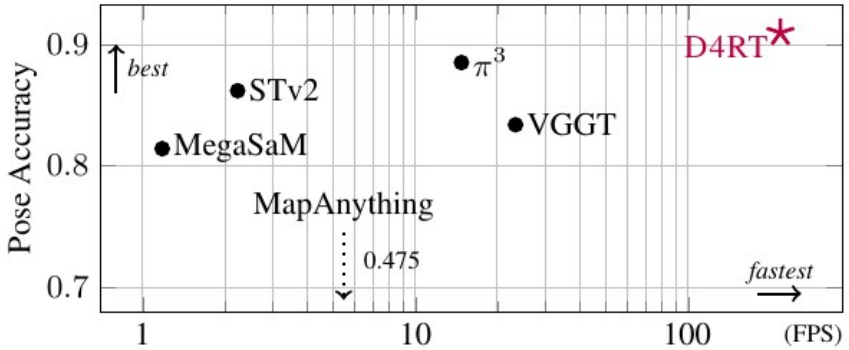


Figure 3. **Pose accuracy *vs.* speed** – D4RT achieves over 200 FPS for pose estimation on an A100 GPU, delivering superior accuracy while running 9× faster than VGGT and 100× faster than MegaSaM. Accuracy is defined as *1 – error*, averaged over ATE / RTE / RPE on Sintel and ScanNet.

論文 Figure 3： A100 姿勢估計超過 200 FPS 比 VGGT 快 9 倍，比 MegaSaM 快 100 倍

論文 Table 3 • 維持 24 FPS 時，能同時算出的整段影片三維軌跡數（單張 A100）

D4RT 1,570 條 **SpatialTrackerV2 84 條**

論文宣稱 18–300 倍。對 SpatialTrackerV2 約 18 倍；對 DELTA 依 FPS 檔位約 7 至 314 倍。台上請說「論文宣稱」。

一看就懂的差別

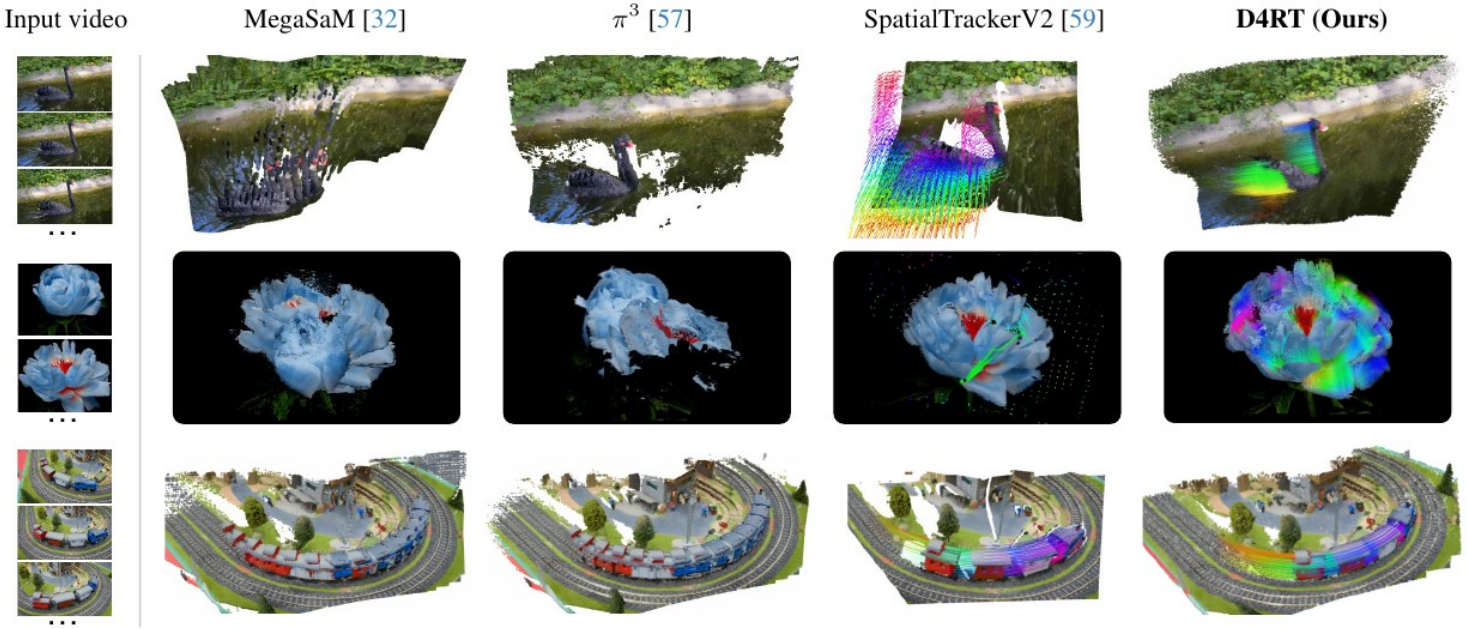


Figure 4. **Reconstruction results across methods** – Pure reconstruction methods (MegaSaM and π^3) are only able to accumulate point clouds of all pixels; exhibiting clear failure cases in dynamic scenes. For example, the swan is repeated in MegaSaM's reconstruction, and π^3 is failing entirely to reconstruct the flower. SpatialTrackerV2, a state-of-the-art tracking method, successfully captures dynamics, however its design only allows tracking points from *one* frame, leaving gaps in the reconstruction (behind the swan and train). D4RT is the only method that successfully reconstructs a full 4D representation of the scene including *all* pixels of the video.

MegaSaM： 天鵝被重複印上　π³： 論文寫成完全重建不出花　SpatialTrackerV2： 單幀追蹤會留缺口　D4RT： 補滿所有像素

論文 Table 4 • TAPVid-3D

追蹤整體領先，但 ADT 並非每格第一

w/ GT intrin.	Method	TAPVid-3D											
		Camera Coordinate 3D tracking									World Coordinate 3D tracking		
		DriveTrack			ADT			PStudio			DriveTrack	ADT	
		AJ ↑	APD_{3D} ↑	OA ↑	AJ ↑	APD_{3D} ↑	OA ↑	AJ ↑	APD_{3D} ↑	OA ↑	APD_{3D} ↑	L1 ↓	APD_{3D} ↑	L1 ↓
✗	St4RTrack [13]	-	-	-	-	-	-	-	-	-	0.020	0.499	0.062	0.839
	CoTracker3 [26] + UniDepthV2 [39]	0.038	0.062	0.856	0.102	0.146	0.937	0.119	0.176	0.862	-	-	-	-
	CoTracker3 [26] + VGGT [51]	0.129	0.189	0.856	0.132	0.190	0.937	0.045	0.070	0.862	0.205	0.170	0.192	0.736
	SpatialTrackerV2 [59]	0.064	0.100	0.865	0.260	0.342	0.936	0.097	0.152	0.805	0.101	0.139	0.336	0.238
	D4RT (Ours)	0.257	0.345	0.875	0.240	0.319	0.926	0.138	0.186	0.897	0.373	0.020	0.319	0.096
✓	CoTracker3 [26] + UniDepthV2 [39]	0.147	0.225	0.856	0.173	0.254	0.937	0.205	0.311	0.862	-	-	-	-
	CoTracker3 [26] + VGGT [51]	0.245	0.342	0.856	0.175	0.250	0.937	0.215	0.318	0.862	0.292	0.160	0.234	0.755
	DELTA [35]	0.170	0.238	0.874	0.199	0.258	0.879	0.175	0.261	0.760	-	-	-	-
	SpatialTrackerV2 [59]	0.195	0.275	0.865	0.303	0.404	0.936	0.175	0.270	0.805	0.201	0.117	0.378	0.263
	D4RT (Ours)	0.304	0.410	0.875	0.307	0.408	0.926	0.372	0.498	0.897	0.470	0.017	0.398	0.093

Table 4. **4D reconstruction and tracking** – We evaluate 3D tracking capability on dynamic videos, with tracks predicted in both local camera coordinates (left) and world coordinates (right). Our model achieves superior performance compared to the prior state-of-the-art.

DriveTrack AJ

0.257

無真實內參；次佳 0.129

世界座標 L1

0.020

DriveTrack； 對照方法 > 0.1

ADT 要老實講

未全贏

無內參時 STv2 的 AJ / APD3D 較高

論文 Table 5 、 Table 6

點雲、深度與姿勢：整體 top-tier

Method	Point Cloud		Video Depth							
	Sintel	ScanNet	Sintel		ScanNet		KITTI		Bonn	
	L1 ↓	L1 ↓	AbsRel (S) ↓	AbsRel (SS) ↓	AbsRel (S) ↓	AbsRel (SS) ↓	AbsRel (S) ↓	AbsRel (SS) ↓	AbsRel (S) ↓	AbsRel (SS) ↓
MegaSaM [32]	1.531	0.072	0.342	0.249	0.050	0.047	0.109	0.101	0.056	0.056
VGGT [51]	1.582	0.063	0.318	0.247	0.044	0.040	0.094	0.067	0.055	0.051
MapAnything [27]	1.718	0.064	0.397	0.306	0.043	0.035	0.096	0.090	0.076	0.049
SpatialTrackerV2 [59]	1.375	0.036	0.209	0.175	0.027	0.025	0.075	0.064	0.042	0.978
π^3 [57]	1.139	0.030	0.241	0.163	0.021	0.019	0.055	0.053	0.033	0.032
D4RT (Ours)	0.768	0.028	0.171	0.148	0.020	0.018	0.055	0.051	0.036	0.036

Table 5. **Video depth and point map estimation** – Quantitative results for both video depth and point map estimation across four benchmarks. D4RT achieves top-tier performance on the depth estimation task under both scale-only (S) and scale-and-shift (SS) alignments.

點雲 L1 · Sintel

0.768

次佳 π^3 為 1.139

深度 AbsRel · Sintel

0.171 / 0.148

最難、高度動態

姿勢 ATE

0.065 / 0.014

Sintel / ScanNet 都是最好

Re10K Pose AUC

83.5

次佳 π^3 為 78.7

沒贏的格子也要講： Bonn 深度是 π^3 較好（0.033 / 0.032 對 0.036 / 0.036）； ScanNet RPE-R 是 π^3 的 0.291 略好於 0.302 。

哪些設計真的有用

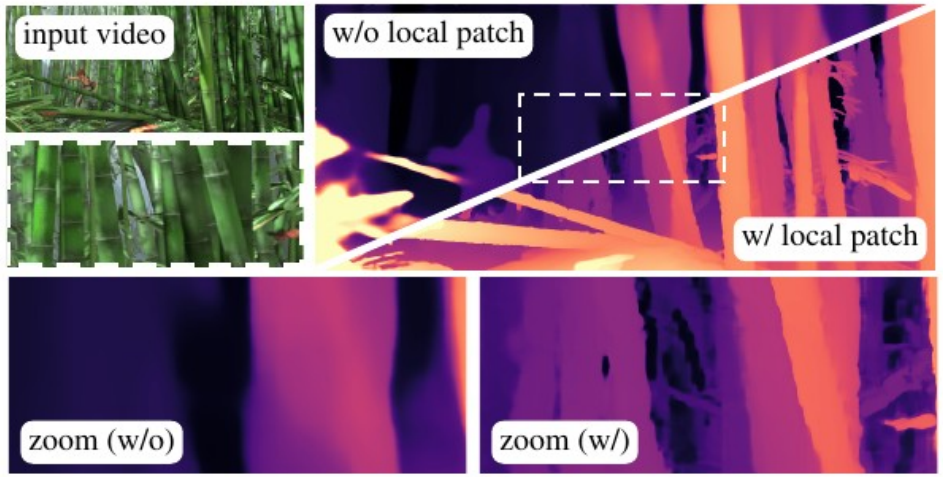


Figure 6. **Preservation of low-level details** – We ablate the effect of including local patch information into the model's queries, visualizing the resulting depth maps on an example from the Sintel dataset. We find that the local RGB patches help preserve fine-grained details and produce sharper object boundaries.

論文 Figure 6： 加上 9×9 局部 RGB patch 後， Sintel 深度邊界明顯更清楚

Table 7　9×9 patch （ViT-L, Sintel）

深度 AbsRel 0.366 → 0.302
相機 ATE 0.173 → 0.091

Table 8　編碼器放大

深度與 RPE-R 大致變好
但 ViT-g 的 ATE 0.078 並未勝過 ViT-H 的 0.070

Table 9　輔助損失

二維位置、法向幫助深度
拿掉信心項， ATE +0.126

論文沒有獨立的 Limitations 小節

限制，以及我們的看法

1

不是每一格都第一

ADT （尤其無真實內參時）、 Bonn 深度、 ScanNet 的 RPE-R，都有對照方法持平或更好。

2

訓練混有內部資料

作者說只用公開資料仍是最先進，但那些數字在附錄，正式 11 頁看不到。

3

48 幀、 256×256

更長或更高解析的影片，正文沒有系統分析。

我們的看法

它把很多看起來不一樣的幾何問題，收成同一個非常好問的問題：任意一點在任意時間、任意相機下的三維位置。再加上數量級的速度優勢，這是我們認為它重要的原因。

總結

三句話收斂

01

一個 query

用獨立查詢問任意點的三維位置，統一深度、點雲、追蹤和相機參數。

02

所以才快

只解需要的點。 A100 上姿勢估計超過 200 FPS ； 全像素追蹤有 Algorithm 1 。

03

整體最先進

多數 4D 基準達到新的 state of the art ， 同時我們指出它並非每一格都贏。

專案頁與動畫 https://d4rt-paper.github.io/

謝謝老師，歡迎提問。